

深圳大学实验报告

课程名称 机器学习

项目名称 实验三：线性回归算法

学 院 计算机与软件学院

专 业 软件工程（腾班）

指导教师 赖志辉

报 告 人 洪子敬 学号 2022155033

实验时间 2024 年 4 月 1 日至 2024 年 4 月 7 日

实验报告提交时间 2024 年 4 月 7 日

教务处制

一、实验目的与要求

1. 简要介绍并实现基本的线性回归算法；
2. 阅读并介绍其它论文中的 2 个回归学习方法（模型与优化都要有）；
3. 自行设计一个全新的线性回归算法（不是别人论文里的！而是自己创造的！展开你的想象力来设计），包括建模与优化，收敛性证明等（如果有），要求：至少在 2~3 个数据库中与（1）中的方法进行实验比较。全方位比较你的方法与你复现的方法在不同维数的识别率。

。

二、实验内容与方法

1. 简要介绍线性回归原理并实现基本的线性回归算法；
2. 介绍进行扩展的线性回归算法，介绍其思想并加以实现；
3. 通过阅读论文提出一个新的回归算法，介绍其的原理思想及相关公式推导。

三、实验步骤与过程

1. LR (Linear Regression) 原理简介

(1) 基本内容：

线性回归是机器学习中最简单，最基础的一类有监督算法，直观易于理解，可解释性强。线性回归要解决的问题是：给定一组样本输入，在某一特定损失下，找到目标值和输入值之间的函数关系，在此基础上，再给定一个新样本下，我们能够预测其对应的目标值是多少。

(2) 模型分解

线性 (Linear) 算法模型：给定 n 个属性 $x = (x_1, x_2, \dots, x_n)$ ，此模型试图学得一个通过各个属性得线性组合来预测的函数，即 $f(x) = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ 。

其中 α_i 为参数， x_i 是输入数据，待模型学得参数之后，模型就可以确定了。

回归 (Regression) 算法模型：回归是相对分类而言，也算是一种分类，但主要针对的是连续型变量，而分类算法针对的是离散型变量。

(3) 模型分类

一元线性回归：只用一个 x 来预测 y ，即用直线来拟合二维数据，形如 $f(x) = w * x + b$ ；

多元线性回归：用多个 x 来预测 y ，即用一个平面来拟合多维数据，此时参数则有多个，形如 $f(x) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$ ；

(4) 模型优化

损失函数：在拟合过程必然出现误差，但我们希望模型能最大程度地拟合所有数据，也就是使得误差最小化，这里的误差我们取“残差”来衡量，即真实值和预测值之间的差值，用公式可表述为 $e = y - \tilde{y}$ ；

在机器学习中，最常见的损失函数使用残差平方和 SSE (sum of squares for error)，如果有进行多批次训练，则要用均方误差 MSE (mean of squares for error)，用公式可以表示为

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{y}_i)^2$$

最小二乘法：基于最小化残差和或者均方误差来求解模型的方法称为最小二乘法，在线性回

归中,此方法就是试图找到一条直线或者平面使得所有样本到该直线或者平面的欧式距离之和最小。下面是线性回归模型的最小二乘“参数估计”:

我们定义损失函数 $Loss = \sum_{i=1}^n (y_i - \tilde{y}_i)^2 = \sum_{i=1}^n (y_i - (\alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n))^2$, 最小化损失函数有两种方法—求导法和梯度下降法。

优化方法 1—求导法

不难发现 $Loss$ 函数是关于 α_i 参数的凸函数,当它关于每个 α_i 的导数都为零时,其达到最小值,此时模型达到最优解,这里为了方便运算采用矩阵的形式进行操作,同时将 X 矩阵加一列1,这样使得 α 与 X 矩阵便于进行乘法运算,因此则有

$$Loss = ||y - X\alpha||_2^2$$

对 α 求导可得

$$\frac{\partial Loss}{\partial \alpha} = 2X^T y - 2X^T X \alpha = 0$$

可得模型的解

$$\alpha = (X^T X)^{-1} X^T y$$

因而对于某个测试样本的预测值

$$\tilde{y} = \alpha^T x$$

Ps: X 矩阵中存放的是 m 个示例,每个示例按行放置,最后一列均为 1,矩阵大小为 $m \times (d+1)$, α 向量为列向量,最后一个为偏置项,向量大小为 $(d+1) \times 1$ 。

优化方法 2—梯度下降法

对于梯度下降法,前面我们知道该损失函数是凸函数,那必然在区间范围内有最小值,继续采用矩阵进行操作,则我们需要找到 $Loss$ 最小时对应的 α 。而梯度下降得思想类似于下山,每次往下走一步,但这一步是该点的负梯度方向,而且每次这一步多大也是有限制的,我们称它为学习率,即 α 的更新方式为

$$\alpha = \alpha - \text{learning_rate} * \alpha;$$

其中 learning_rate 也是我们需要严格控制的变量,既不能太大也不能太小,太大会是我们走过了谷底,在谷底两边来回走;太小虽然能保证走到谷底,但会计算多次梯度,消耗资源多,同时耗时也长,因此 learning_rate 的确定很关键。

Ps: 对于梯度下降法,实际上我们在前面的损失函数 $Loss$ 前在加个 $1/2$,这样我们可以使得求导后没有常数项,使得计算更加简洁。

(5) 算法流程:

- I. 读入数据并将数据按照(样本数*特征数)的格式进行存放,并将对应的标签按照(样本数*1)的格式进行存放,并在训练集末尾加一列 1;
- II. 在训练集进行模型训练得到 θ ;
- III. 对测试集进行预测反应模型性能。

2. LR 的简单编码实现 (matlab)

在前面我们已经知道了线性模型的解,这也是机器学习中极少数不多的可以直接解出解的模型,我们这里直接使用其解进行模型求解(当然也可以设置学习率,用梯度下降的算法进行求解,这里为了方便直接使用求导法进行编写代码),具体代码如下所示:

```
function theta=Regression(X,y)
% input:X->training set [samples_num,features]
% y->label of the training set [samples_num,1]
% output:theta:[features,1]
theta=(X'*X)^(-1)*X'*y;
end
```

洪子敬 腾班
2022155033


在主函数中对其进行测试（测试集从网上下载而来，只有两个特征的简单数据集）
我们将模型训练好了之后得到对应的 theta，利用其返回来预测 y 的取值，并将原来的真实取值和预测取值分别化成图进行展示，具体代码如下所示：

```
% typedef data set
data=load('data.txt');
X=data(:,1:2);
[~,~]=size(X);
X=[ones(row,1) X];
y=data(:,3);
theta=Regression(X(1:40,:),y(1:40));
y_predict=zeros(row,1);

for i=1:40
    y_predict(i)=X(i,:)*theta;
end
figure(1);
scatter(X(1:40,2),y(1:40),'r','s','filled');
figure(2);
scatter(X(1:40,2),y_predict(1:40),'r','s','filled');
```

洪子敬 腾班
2022155033

模型效果如下所示（左图为原始点集，右图为预测点集）



观察上图我们可以明显看到模型拟合的相当不错，肉眼可见得是一条直线。

3. Ridge Regression（岭回归）

（1）基本思想

当样本特征较多而样本数量较少时（实验时基本都是这种情况），简单的线性模型很容易进入过拟合，我们考虑加入正则项，使用 L2 范数进行正则化，则有

$$\min_w \sum_{i=1}^n (y_i - w^T x_i)^2 + \lambda \|w\|_2^2$$

当模型过拟合时， w_i 的差异会非常大，通常是偏大，这时我们加入正则项可以限制一下权重不要太大，均衡一些，下面用求导法给出其求解过程：

定义损失函数为

$$\begin{aligned} Loss &= \min_w \sum_{i=1}^n (y_i - w^T x_i)^2 + \lambda \|w\|_2^2 \\ &= \min_w \|y - Xw\|_2^2 + \lambda \|w\|_2^2 \\ &= \min_w \text{tr}((y - Xw)^T (y - Xw) + \lambda w^T w) \end{aligned}$$

这里不加任何的常数辅助运算，因为自己会抵消的；

$$\frac{\partial Loss}{\partial w} = -2X^T y + 2X^T X w + 2\lambda w = 0$$

解得：

$$w = (X^T X + \lambda I)^{-1} (X^T y)$$

(2) 代码实现及测试

岭回归的代码实现也是和简单 LR 模型实现一致，都是直接用求导法进行求解，具体代码如下所示：（梯度下降算法不多加展示）

```
function theta=Ridge_regression(X, y, lambda)
% input:X->training set [samples_num, features]
% y->label of the training set [samples_num, 1]
% lambda->penalty degree
% output:theta:[features, 1]
n=size(X, 2);
I=eye(n);
theta=(X'*X+lambda*I)^(-1)*(X'*y);
end
```

洪子敬 腾班
2022155033

为了测试模型效果，我们选用了不同的 lambda 来测试模型的损失函数 Loss，同时选择了 lambda=0.05 来对模型进行预测，具体代码如下所示：

```
% RidgeRegression
lambda=(0.001:1:100);
errors=zeros(length(lambda), 1);
for i=1:length(lambda)
    theta=Ridge_regression(X, y, lambda(i));
    y_predict=zeros(40, 1);
    for j=1:40
        y_predict=X(j, :)*theta;
    end
    errors(i)=sum(sqrt((y-y_predict).^2));
end
plot(lambda, errors);



% lambda=0.05;
theta=Ridge_regression(X, y, lambda);
y_predict=zeros(40, 1);
for j=1:40
    y_predict(j)=X(j, :)*theta;
end
scatter(X(1:40, 2), y_predict(1:40), 'r', 's', 'filled');
```

洪子敬 腾班
2022155033

洪子敬 腾班
2022155033

Ps: 这里的.^是 matlab 中对矩阵的向量化操作，对列中的每个元素进行平方。

具体效果如下所示：



观察损失函数可知 lambda 在较低时取得的效果较好（但也不能太小防止过拟合）；

观察拟合函数我们不难发现直线附近的点不像之前拟合的那样严格，有一定的容忍；

4. Lasso Regression (拉索回归)

相对于岭回归,我们将其这个正则化项改为 L1 范数就是 Lasso 回归,其代价函数如下所示:

$$Loss = \min_w \sum_{i=1}^n (y_i - w^T x_i)^2 + \lambda ||w||$$

其求解过程这里不多加展示,因为 L1 范数是向量的绝对值之和,这里不好表示;

使用 L1 范数的好处:一是可以降低过拟合的风险,二是更加易于获得稀疏(sparse)的解,即求得的 w 会有更少的非零分量。基于这一点, Lasso 回归进行特征选择的时候,可以将特征选择和学习器训练结合在一起,两者在同一个优化过程完成,这称为嵌入式选择。

$$w_j = \begin{cases} \left(m_j - \frac{\lambda}{2}\right), & \text{当 } m_j > \frac{\lambda}{2} \\ 0, & \text{当 } m_j \in \left[-\frac{\lambda}{2}, \frac{\lambda}{2}\right] \\ \left(m_j + \frac{\lambda}{2}\right), & \text{当 } m_j < -\frac{\lambda}{2} \end{cases}$$

其中 $m_j = \sum_{i=1}^n x_i^j (y_i - \sum_{k \neq j} w_k x_i^k)$;

(有关稀疏性的证明较为复杂这里不加展示,主要运用数学推导,求出的每一个 w 分量都是分段函数的分布,并不连续,因而可以得出稀疏性的结论)

5. Spectral Regression: A Unified Approach for Sparse Subspace Learning*

(谱回归:稀疏子空间学习的一种统一方法)

问题背景:近年来,维度约简受到了广泛的关注,常用的方法如 PCA、LDA、LPP 等,但这些方法都存在一个缺点就是学习到的投影函数是原来的所有原始特征的线性组合,因此结果总是难以解释。而统一稀疏子空间学习框架(USSL)将学习投影函数转化为一个回归框架,以便于使用各种正则化器,同时此文章也实验证实了其方法的有效性。

基于子空间的图嵌入式视图:

给定 m 个数据点 x_i (图 G 的 m 个顶点), W 是 $m \times m$ 的对称矩阵,其中 W_{ij} 表示顶点 i 与顶点 j 之间的边的权值, G 和 W 可以用于表征数据集的一些几何属性,图嵌入的目的是将图的每个顶点表征为一个低维向量,同时保持顶点之间的相似性,其中相似性用边的权值来表征。

我们不妨假设 $y = \{y_1, y_2, y_3, \dots, y_n\}$ 为图到实线的映射,即数据点 x 到 y 的映射,则最优化 y 是通过最小化

$$\sum_{i,j} (y_i - y_j)^2 W_{ij}$$

通过最小化这个式子,在适当的约束下,我们可以确保第 i 个顶点到第 j 个顶点被映射地够足够接近,如映射地过远的话,则会给予沉重的惩罚。

利用代数公式上面式子可以化为

$$\begin{aligned} & \sum_i \sum_j (y_i^T y_i - 2y_i^T y_j + y_j^T y_j) W_{ij} \\ &= \sum_i \sum_j (y_i^T y_i - 2y_i^T y_j + y_j^T y_j) W_{ij} \\ &= 2Y^T D Y - 2 \sum_i \sum_j y_i^T y_j W_{ij} \\ &= 2Y^T D Y - 2 \sum_i \sum_j y_i^T y_j W_{ij} \\ &= 2Y^T D Y - 2Y^T W Y \\ &= 2Y^T L Y \end{aligned}$$

其中 D 为 W 的行和或者列和的对角矩阵, $L=D-W$, L 称为图拉普拉斯矩阵;

于是上述问题可以化为

$$\min Y^T L Y \quad s.t. Y^T D Y = 1$$

上述问题等效为

$$\max Y^T W Y \quad s.t. Y^T D Y = 1$$

用拉格朗日乘子法并将其化简我们不难得到下式

$$W Y = \lambda D Y \quad ①$$

$$\text{设 } Y = X^T \alpha. \text{ 则上式可化为 } X W X^T \alpha = \lambda X D X^T \alpha \quad ②$$

因此，通过求解最大特征值得特征问题我们可以得到最优的 Y 值。

除此之外此论文还提出了用此图嵌入进行线性扩展 (LGE)，主要区别在 W 矩阵的选择，文章提供了关于 LDA, LPP, NPE 等流行的线性降维算法得 W 矩阵的选择，这里不加赘述。

谱回归：为了将上面的 LGE 方法建模为一个回归型优化问题，文章给定下面的定理：

定理：设①式的特征向量为 y，具有特征值 λ ，若有 $y = X^T \alpha$ ，则 α 是特征问题②中的特征向量，且具有相同的特征值 λ 。

利用上面的定理，为了能找到满足 $y = X^T \alpha$ 的 α ，实际上这样的 α 可能不存在，一种可能的方法就是采用最小二乘法来拟合方程：

$$\alpha = \operatorname{argmin}_{\alpha} \sum_{i=1}^m (\alpha^T x_i - y_i)^2$$

在前文中我们提到当样本特征大于样本数量时，最小化上面问题可能是病态的，即有可能有无穷多个解，于是文章采用正则化技术，对 α 的范数采用惩罚机制。而 L1 范数和 L2 范数是最常见的正则化技术。

正如我们之前所提到的，Lasso 回归虽然产生的稀疏模型正是我们想要的，但其选择的特征数量受样本数量的限制，这显然是让人不满意的，于是文章结合 Ridge 回归和 Lasso 回归进行实验，加入惩罚后如下所示：

$$\alpha = \operatorname{argmin}_{\alpha} (\sum_{i=1}^m (\alpha^T x_i - y_i)^2 + \beta \sum_{j=1}^n \alpha_j^2 + \gamma \sum_{j=1}^n |\alpha_j|)$$

文章也说明了上式的解即为②式的特征向量，当 β, γ 趋于 0 时且 y 在 X 的张量空间中。

基于上面两步，本质上是在图的谱分析之后进行回归，文章称之为谱回归，并通过 Lasso 惩罚，提供了统一的稀疏子空间学习框架 (USSL)。

USSL 计算分为**响应生成**（计算①的特征向量）和**正则化回归**，而此框架最大贡献在于不仅为系数子空间学习提供了一种有效的方法，也将 LGE 通过谱回归建立了**线性模型**进行求解。

四、实验结论或体会

实验结论：

本次实验成功设计了简单 LR 算法，并介绍了其相关正则化扩展—岭回归和拉索回归，也介绍较新的一种回归方法 (USSL)。同时也复现了简单线性回归模型和岭回归模型，取得了较好的结果，本次实验圆满结束。

实验体会：

本实验最大的收获就是对线性回归牢牢掌握并且有了一些新的理解,在学习完 PCA 之后,很多的模型都可以从同一个优化问题出发,这有利于让我们联系所有已学知识,实现知识的联系和贯通。

此外,本实验采用了也实现一些论文的思想,这是我为数不多精读的一篇论文,挺有启发的,也去理解了一下 LPP, NPE 这些模型,发现这些与流行结构的一些论文比如 isomap 思想和推到很相似,之前还没完全地将流行结构思想理解清楚和复现,后面会去好好阅读并结合起来理解,这次试验也让我感受到将论文复现亦或是理解出来很有成就感,可惜的是这篇文章并没有复现的部分,也有自己时间不够的问题,后面会合理安排时间来学习。

另外实验过程中也发现自己很多不足的地方,比如数学方面矩阵的计算还是有许多的不足之处,还得自己去整理,理解各种范数,多进行矩阵运算,这样才能熟能生巧。前路漫漫,还得继续加油!

参考文献:

- [1] 2-4 regression-Spectral Regression A Unified Approach for Sparse Subspace Learning
- [2] [机器学习基础---降维方法---局部保持投影 \(LPP\) 推导_lpp 机器学习-CSDN 博客](#)
- [3] 2-3 regression-L21-Norm Regularized Discriminative Feature Selection for Unsupervised Learning OK
- [4] [邻域保留投影算法 \(NPE\) \(Neighborhood Preserving Embedding\) 算法详解-CSDN 博客](#)

指导教师批阅意见:

成绩评定:

指导教师签字:

年 月 日

备注:

注：1、报告内的项目或内容设置，可根据实际情况加以调整和补充。