

# 深圳大学实验报告

课程名称 机器学习

项目名称 实验二：LDA 算法

学 院 计算机与软件学院

专 业 软件工程（腾班）

指导教师 赖志辉

报 告 人 洪子敬 学号 2022155033

实验时间 2024 年 3 月 18 日至 2024 年 3 月 24 日

实验报告提交时间 2024 年 3 月 24 日

教务处制

## 一、实验目的与要求

1. 简述 LDA 原理，算法模型与优化问题，并给出求解的全程推导细节；
2. 给出 LDA 的各种等价模型表示(除法的、减法的及其调换位置的等)，在各数据集（不少于 3 个）比较 PCA 与“LDA 的各种等价模型与正则模型”的人脸识别精度；
3. 比较 eigenface 与 fisherface 的不同，并取 3 个类的图像投影在二维和三维空间中，并用不同颜色的点表示不同的类，每个类选 3 个有代表性的点对应的人脸图像显示在该点的边上（用 plot 命令或 imshow），比较 PCA 与 LDA 的结果的异不同。
4. 参看前人其它论文实现一个新的线性鉴别分析方法或子空间学习方法，并 PCA, LDA 做比较实验，打印出各方法训练样本数的增长其识别曲线变化图等各种情况，把简要内容写在本实验报告中。

## 二、实验内容与方法

1. 简述 LDA 的原理并证明  $S_t = S_b + S_w$ ；
2. 给出 LDA 各种模型表示，并用 matlab 实现 LDA 算法的各种等价模型，并在三个数据集上比较各个 LDA 等价模型与 PCA 算法的人脸识别精度；
3. 利用人脸重构来对比 eigenface 和 fisherface 的不同，并用三个类在二维和三维空间中进行投影，用不同颜色的点表示不同的类别，每个类选择三个代表性的点，并将该人脸图片显示在旁边，比较 PCA 和 LDA 的效果；


## 三、实验步骤与过程

### 1. LDA (Linear Discriminant Analysis) 原理简介

#### (1) 基本内容：

LDA 线性判别分析，是一种监督学习算法，但在二分类问题上，由于最早由 Ronald Fisher 提出，所以也称为 Fisher 判别分析 (FDA)，但 LDA 与 FDA 还是有些区别的，LDA 假设各类样本数据都是高斯分布，协方差矩阵相同且满秩。相比 PCA，LDA 是有监督的降维算法，即数据是有标签的（类别标签）。

如右图所示的数据，根据 PCA 算法，数据应该映射到数据方差最大的方向，即垂直方向（红线方向），但是图示中的两个类别将完全混合混在一起，很难区分开，这时候我们发现采用 PCA 算法来解决问题的效果非常差，但是如果采用 LDA，数据将映射到水平轴方向（蓝线方向），这时候我们发现同类数据比较集中，不同类的数据被完全地分开，效果正如我们想要的那样。



#### (2) 二分类 LDA 原理推导

LDA 主要是为了分类，所以相应的投影方向  $w$ ，使得投影后的数据尽可能按照原始的类别进行分开，我们仍从上面的二分类问题出发，我们假设两个类别的均值(中心)分别为  $\mu_1 = \sum_{x \in C_1} x / N_1$ ， $\mu_2 = \sum_{x \in C_2} x / N_2$ 。我们希望投影后两个类的距离尽可能，这样易于区分，类间距离可以表示为  $D(C_1, C_2) = \|\tilde{\mu}_1 - \tilde{\mu}_2\|^2$  ( $\tilde{\mu}_1$ ,  $\tilde{\mu}_2$  表示两类中心在  $w$  方向上的投影向量) 其中  $\tilde{\mu}_1 = w^T \mu_1$ ,  $\tilde{\mu}_2 = w^T \mu_2$ , 因此优化问题为

$$\max_w ||w^T(\mu_1 - \mu_2)||_2^2 \quad s.t. \quad w^T w = 1$$

不难发现，当  $w$  方向与  $(\mu_1 - \mu_2)$  方向一致时，该距离达到最大值，但若按照最大化两类投影中心距离的准则进行降维时，原本可以被线性划分的样本，经过投影会有一定程度的重叠，这显然与我们的要求不符。于是我们退一步，减少一点两类中心的投影距离，换来样本投影后的可分性，这是我们发现每一类的数据更加集中。于是我们得出了 LDA 的中心思想——**最大化类间距离和最小化类内距离**。

在之前的基础上，我们用两类的方差来表征类内距离，不妨令

$$D1 = \sum_{x \in C1} (w^T x - w^T \mu_1)^2 = \sum_{x \in C1} w^T (x - \mu_1)(x - \mu_1)^T w,$$

$$D2 = \sum_{x \in C2} (w^T x - w^T \mu_2)^2 = \sum_{x \in C2} w^T (x - \mu_2)(x - \mu_2)^T w,$$

则两类投影后的方差为  $D1+D2$ 。结合两式得出我们最终的目标函数：

$$\max_w J(w) = \frac{||w^T(\mu_1 - \mu_2)||_2^2}{D1+D2} = \frac{w^T(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w}{\sum_{x \in C1} w^T (x - \mu_1)(x - \mu_1)^T w}$$

为此我们定义**类间散度矩阵**为  $S_b = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$ ,

**类内散度矩阵**为  $S_w = \sum_{x \in C1} (x - \mu_1)(x - \mu_1)^T$ ,

则目标函数可以化为  $\max_w J(w) = \frac{w^T S_b w}{w^T S_w w}$

方法一：利用**拉格朗日乘子法**，不妨令  $w^T S_w w = 1$ ，则原式可化为

$$w^T S_b w + \lambda(w^T S_w w - 1) = 0, \quad s.t. \quad w^T S_w w = 1$$

对  $w$  求导可得

$$S_b w = \lambda S_w w$$

方法二：**直接求导法**，只需对  $w$  求偏导并令导数为 0，则有

$$\frac{\partial J(w)}{\partial w} = \frac{\frac{\partial w^T S_b w}{\partial w} w^T S_w w - \frac{\partial w^T S_w w}{\partial w} w^T S_b w}{(w^T S_w w)^2} = 0;$$

化简得  $(w^T S_w w) S_b w = (w^T S_b w) S_w w$ ;

不妨令  $\lambda = J(w) = \frac{w^T S_b w}{w^T S_w w}$ ，则上式可以写为  $S_b w = \lambda S_w w$

整理得： $S_w^{-1} S_b w = \lambda w$  (其中  $\lambda$  为拉格朗日常数)

从此处我们可以看出我们最大化的目标变成了一个矩阵的特征值，于是 LDA 降维变成了一个求矩阵特征向量的问题，其中  $J(w)$  对应于矩阵  $S_w^{-1} S_b$  最大的特征值，而投影方向就是这个特征值对应的特征向量。而对于我们这个二分类问题，由于  $S_b w$  方向始终与  $\mu_1 - \mu_2$  方向一致，如果我们只考虑  $w$  的方向而不考虑大小，则  $w = S_w^{-1}(\mu_1 - \mu_2)$ ，因此我们只需要知道样本的均值和类内方差即可得出最佳投影方差，这是 Fisher 在 1936 年提出的线性判别分析。

### (3) 多分类 LDA 原理推导

按照我们之前的定义，当类别扩展到  $n$  个时，类内散度矩阵定义还是成立的，但类间散度矩阵的就无法满足，于是我们需要定义一个全局的散度矩阵来表示整体的散度，称为全局散度矩阵  $S_t = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$ ，其中  $\mu$  表示全部样本的中心，所有中心的均值。根据我们之前的定义无法表示类间散度矩阵，不妨用投影之后每一类中心点与所有类中心

点的距离之和来衡量类间的距离，由于每一类的样本点数量可能不同，我们把每一类中心点与所有类中心点的距离加上权值之后再求和，即类间距离可以表示为

$$S_b = \sum_{i=1}^n m_i (\mu_i - \mu)(\mu_i - \mu)^T$$

此时的类间散度矩阵表示的是每类中心到全局中心的加权和，而此时我们最大化类间距离既是使得每个类的中心离全局中心最远，为此我们将最大化目标函数定为：

$$\max_w J(w) = \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_w W)}$$

其中  $W$  是我们要求的投影超平面，且满足  $W^T W = 1$ ，我们可以采用如下广义特征值求解的方式进行求解： $S_b W = \lambda S_w W$

求解得最佳投影平面  $W$ ，即求得了  $S_w^{-1} S_b$  矩阵前  $k$  个最大特征值对应的特征向量组成的矩阵（ $k$  为下降到的维数，也是投影向量的数量）。

(4) 证明： $S_t = S_b + S_w$

$S_t$  总体散度矩阵本质上就是 PCA 的优化目标，要证明  $S_t = S_b + S_w$ ，即证明  $S_b = S_t - S_w$ ，由于

$$S_t = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T;$$

$$S_w = \sum_{x \in C_i} (x - \mu_i)(x - \mu_i)^T;$$

则证明过程如下：

$$\begin{aligned} S_t - S_w &= \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T - \sum_{x \in C_i} (x - \mu_i)(x - \mu_i)^T \\ &= \sum_{i=1}^C \sum_{j=1}^{N_i} (x_i^j - \mu)(x_i^j - \mu)^T - \sum_{i=1}^C \sum_{j=1}^{N_i} (x_i^j - \mu_i)(x_i^j - \mu_i)^T \\ &= \sum_{i=1}^C \sum_{j=1}^{N_i} (x_i^j x_i^{jT} - x_i^j \mu^T - \mu x_i^{jT} + \mu \mu^T - x_i^j x_i^{jT} + x_i^j \mu_i^T + \mu_i x_i^{jT} - \mu_i \mu_i^T) \\ &= \sum_{i=1}^C \sum_{j=1}^{N_i} (-x_i^j \mu^T - \mu x_i^{jT} + \mu \mu^T + x_i^j \mu_i^T + \mu_i x_i^{jT} - \mu_i \mu_i^T), \\ &= \sum_{i=1}^C (-\sum_{j=1}^{N_i} x_i^j \mu^T - \sum_{j=1}^{N_i} \mu x_i^{jT} + \sum_{j=1}^{N_i} \mu \mu^T + \sum_{j=1}^{N_i} x_i^j \mu_i^T + \sum_{j=1}^{N_i} \mu_i x_i^{jT} - \sum_{j=1}^{N_i} \mu_i \mu_i^T) \\ &= \sum_{i=1}^C (-N_i \mu_i \mu^T - N_i \mu \mu_i^T + N_i \mu \mu^T + N_i \mu_i \mu_i^T + N_i \mu_i \mu_i^T - N_i \mu_i \mu_i^T) \\ &= \sum_{i=1}^C N_i (-\mu_i \mu^T - \mu \mu_i^T + \mu \mu^T + \mu_i \mu_i^T) \\ &= \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T = S_b \end{aligned}$$

即证

(5) 算法流程：

输入：数据集  $X = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，其中  $x_i$  为  $n$  维向量， $y_i$  为类别标签，降至的维度为  $k$  维；

- I. 计算数据集每个类别的均值向量  $\mu_i$  和总体均值向量  $\mu$ ；
- II. 计算类内散度矩阵  $S_w$ ，全局散度矩阵  $S_t$ ，并得到类间散度矩阵  $S_b = S_t - S_w$ ；
- III. 对矩阵  $S_w^{-1} S_b$  进行特征值分解，并将特征值从大到小进行排序；
- IV. 取前  $k$  大的特征值对应的特征向量，并通过  $x' = W^T x$  将  $n$  维样本降至  $k$  维。

## 2. LDA 等价模型说明及编码实现 (matlab)

模型说明：

(1) 除法模型（经典模型）

$$\max_w J(w) = \frac{tr(W^T S_b W)}{tr(W^T S_w W)} \quad \text{s.t. } tr(W^T S_w W) = 1$$

抑或可以写为：

$$\min_w J(w) = \frac{tr(W^T S_w W)}{tr(W^T S_b W)} \quad \text{s.t. } tr(W^T S_w W) = 1$$

模型的解仍为  $S_w^{-1} S_b$  前  $N-1$  个广义特征值所对应的特征向量所组成的矩阵。

(2) 减法模型

$$\max_w J(w) = tr(W^T S_b W) - tr(W^T S_w W) \quad \text{s.t. } tr(W^T W) = 1$$

抑或可以写为：

$$\min_w J(w) = tr(W^T S_w W) - tr(W^T S_b W) \quad \text{s.t. } tr(W^T W) = 1$$

构造拉格朗日函数：

$$L = tr(W^T S_b W) - tr(W^T S_w W) - \lambda (tr(W^T W) - 1)$$

对  $W$  求导并令式子为 0：

$$\frac{\partial L}{\partial W} = 2S_b W - 2S_w W - 2\lambda W = 0$$

即有：

$$(S_b - S_w)W = \lambda W$$

因此此时问题的解是  $S_b - S_w$  的前  $N-1$  个广义特征值所对应的特征向量所组成的矩阵。

(3) 除法正则模型

$$\max_w J(w) = \frac{tr(W^T S_b W)}{tr(W^T S_w W)} + \lambda tr(W^T W) \quad \text{s.t. } tr(W^T S_w W) = 1$$

构造拉格朗日函数：

$$L = W^T S_b W + \lambda tr(W^T W) - \vartheta (tr(W^T S_w W) - 1)$$

对  $W$  求导并令式子为 0：

$$\frac{\partial L}{\partial W} = 2S_b W + 2\lambda W - 2\vartheta W = 0$$

即有：

$$S_w^{-1}(S_b + \lambda I)W = \vartheta W$$

因此此时问题的解是  $S_w^{-1}(S_b + \lambda I)$  的前  $N-1$  个广义特征值所对应的特征向量所组成的矩阵。

Ps：由于减法正则模型本身与减法模型相差不大，这里不多加叙述，只是再加了一个正则项而已，作用并不大，因此我们正则模型只选用除法的正则模型。

Matlab 编码实现：

(1) 基于二分类的 LDA

根据之前的二分类 LDA 的介绍，我们可以知道我们要计算的投影向量  $w = S_w^{-1}(\mu_1 - \mu_2)$ ，

因此我们只需要计算出 $S_w$ 和 $\mu_1, \mu_2$ 就可以计算出相应的投影向量。而在代码上我是将数据进行拆解，分成两个类，并计算每个类各自的样本数，接着分别计算两个类各自的均值向量和类内散度矩阵，最后得到相应的投影方向。具体代码如下所示：


```
% input:X->dataset Y->label
% return projection matrix
function w=Two_Class_LDA(X,Y)
    [n,col]=size(X);
    X1=[]; % class one
    X2=[]; % class two
    for i=1:col
        if(Y(i)==1)
            X1=[X1 X(:,i)];
        else
            X2=[X2 X(:,i)];
        end
    end
end
```

```
% calc mean
mean1=mean(X1,2);
mean2=mean(X2,2);
% calc Sw
Sw1=(X1-mean1)*(X1-mean1)';
Sw2=(X2-mean2)*(X2-mean2)';
Sw=Sw1+Sw2;
% calc w
w=Sw^(-1)*(mean1-mean2);
% normalize
w=w/norm(w);
```

洪子敬 腾班  
2022155033  
2024.3.24

洪子敬 腾班  
2022155033  
2024.3.24

为了测试这个代码的正确性，我随机采用了一组二维数据，两类共 12 个数据，每类 6 个数据。测试效果如下所示（左图为原始数据分布，右图为降维后的数据分布）



从实验结果我们可以看到，投影后的数据两个类都被较好的分开，而且同一类的点也较为接近，效果较为理想。

## （2）基于多分类的 LDA

按照之前的算法流程，我们首先计算出每类的均值向量和总体均值向量，并按照公式计算了类内散度矩阵  $S_b$  和类间散度矩阵  $S_w$ ，具体代码如下所示：

```
%input:X->dataset Y->label cnt->numbers of classes
% return projection matrix
function W=Multi_Class_LDA(X,Y,cnt)
    [feature_num,sample_num]=size(X);
    N=zeros(1,cnt); % size of the each class
    for i=1:sample_num
        N(Y(i))=N(Y(i))+1;
    end
    % calc mean and Sw
    means=[];
    Sw=zeros(feature_num,feature_num);
    index=1;
    for i=1:cnt
        one_class=X(:,index:index+N(i)-1);
```

```
% 对矩阵的每一列求平均值形成一个列向量
means=[means mean(one_class,2)];
S=(one_class-repmat(means(:,i),1,N(i)))*(one_class-repmat(means(:,i),1,N(i)))'/N(i);
Sw=Sw+S;
index=index+N(i);
end
% calc Sb
Sb=zeros(feature_num,feature_num);
averaged_mean=mean(X,2);
for i=1:cnt
    Sb=Sb+N(i)*(means(:,i)-averaged_mean)*(means(:,i)-averaged_mean)';
end
```

洪子敬 腾班  
2022155033  
2024.3.24

洪子敬 腾班  
2022155033  
2024.3.24

而根据之前所介绍的等价模型，我们可以通过不同的方式，来计算对应的降维矩阵，一是经典的 $S_w^{-1}S_b$ ，二是减法模型的 $S_b - S_w$ ，三是正则化模型 $S_w^{-1}(S_b + \lambda I)$ ，选择这三种模型其中一个来进行特征分解就可以得到相应的降维矩阵，具体求解代码如下所示：

```
% Classic
covMatrix=pinv(Sw)*Sb;
% Regular
Sb=Sb+eye(feature_num)*10^-6;
covMatrix=pinv(Sw)*Sb;
% sub
covMatrix=Sb-Sw;
% calc eig_vectors,eid_values
[V,D]=eig(covMatrix);
% sort in descending order
eig_values=diag(D);
[~,index]=sort(eig_values,'descend');
W=V(:,index);
```


洪子敬 腾班  
2022155033  
2024.3.24

(pinv 是求伪逆矩阵的一种函数)


### 在多个数据集上比较 PCA 和 LDA 的效果：

整体思路：我们使用了 ORL, AR, Yale 数据集进行测试，每个数据集选择了 10 类人脸，每类选择前 6 张图片来作为训练集，后 4 张作为测试集。使用 LDA 的三种等价模型，PCA 分别降维至 1、4、7、...、43 维进行人脸识别测试，其中识别的分类器采用 k=4 的 KNN 分类器，具体实验结果展示如下所示：


在 AR\_Gray\_50by40 数据集上的表现：



在 ORL56\_46 数据集上的表现：



在 Yale\_face10080 数据集上的表现：



由实验结果我们可以发现在 ORL, AR 数据集上 PCA 的效果都表现得不错，在 Yale 数据集表现就稍微差些，主要原因也是因为 ORL, AR 数据集上每类人类人脸的主特征都基本一致，而 Yale 上人脸上面部变化较多，产生的噪声较多导致提取的主成分含有混淆信息，致使分辨效果不好；而对于 LDA 我们其实可以看到经典的除法 LDA 模型效果在三种等价模型中其效果是比较好的且稳定的，虽然个别数据集上减法模型和正则模型可能好一些，但稳定性要差一些，同时相比 PCA 在 ORL, AR 数据集上总体较差一些，但在 Yale 上效果却较 PCA 要好，虽然识别率也不是很高，我猜测可能是光影和仪态等噪声的影响。

### 3. 比较 eigenface 和 fisherface 的不同，并实现数据空间可视化


## (1) eigenface 和 fisherface 的比较

整体思想：为了来比较 eigenface 与 fisherface 的不同之处，我采用人脸重构的方式来看一下两种降维方法所提取的特征区别，具体而言，是取前 1、2、...、8 的特征向量对任意选取的一张人脸进行降维和重构，公式为  $\text{reshape}_{\text{face}} = \text{features} * (\text{features}' * \text{face})$ ，并用 imshow 函数进行图片的展示，重构的代码（Rebuild 函数）如下所示：

```
% input: projection matrix, testing set, row of the image, col of the image]
function Rebuild_LDA(W, X_test, row, col)
    figure(1);
    one_face=X_test(:,1);
    index=1;
    for dimension=1:1:8
        chosen_features=W(:,1:dimension);
        reshaped_face=chosen_features*(chosen_features'*one_face);
        real_of_face=real(reshaped_face);
        imag_of_face=imag(reshaped_face);
        subplot(2,4,index);
        index=index+1;
        tmp=reshape(real_of_face+imag_of_face,row,col);
        fig=imshow(mat2gray(reshape(tmp,row,col)));
        title(sprintf("LDA dimension=%d",dimension),FontSize=6);
    end
    waitfor(fig);
end

% input: [Dimensionality reduction matrix,Face to be reconstructed,
%         row of image,column of image,mean of training set]
function Rebuild_PCA(features,X_test,row,col,mean)
    figure(2);
    face=X_test(:,1);
    index=1;
    for dimension=1:1:8
        chosen_features=features(:,1:dimension);
        reshaped_face=chosen_features*(chosen_features'*face);
        reshaped_face=reshaped_face+mean;
        subplot(2,4,index);
        index=index+1;
        fig=imshow(mat2gray(reshape(reshaped_face,row,col)));
        title(sprintf("PCA dimension=%d",dimension),FontSize=6);
    end
    waitfor(fig);
end
```

重构的效果如下所示：



由图像我们可以明显的看出两者的区别

LDA 重构的基本是人脸的整体框架轮廓，是整体的印象，趋向于对人脸进行分类；

PCA 重构的基本是人脸的主要特征，是具体细节的把控，趋向于对人脸特征进行提取；

## (2) 数据的二三维可视化


采用 AR\_Gray\_50by40 数据集进行实验，同时选择三个类，每类 10 张图片，前 7 张作为训练集，后 3 张作为测试集，利用训练好得出的降维矩阵，分别降至二维和三维空间，并展示对应的图像位置，并在旁边展示对应的人脸图像。为此我编写了 FisherVisualiztion 和 EigenVisualiztion 两个函数来实现，基本的作用就是将数据进行二三维降维之后再二三维空间进行展示，同时展示对应的人脸图像（至于为什么要分两个函数写，一是为了区分两种降维方法，显示更清楚，二是 PCA 中数据要进行归一化处理，要减均值，LDA 不用）

Ps：为了在图像中每个点显示对应的图像，我查阅了很多资料，最终终于找到在二维中显示对应图像的方法，具体代码如右图所示：


```
figure(1);
scatter(Y_test(1,:),Y_test(2,:),25,color,'filled');
for i=1:samples
    if(test_label(i)==1)
        scatter(Y_test(1,i),Y_test(2,i),'r','g','filled');
    elseif(test_label(i)==2)
        scatter(Y_test(1,i),Y_test(2,i),'b','d','filled');
    elseif(test_label(i)==3)
        scatter(Y_test(1,i),Y_test(2,i),'g','o','filled');
    end
    hold on;
    picture=X_test(i,i);
    picture=reshape(picture,row,col);
    picture = imrotate(picture,180);
    colormap(gray(256));
    image('CData', picture, 'XData', [Y_test(1,i)-160 Y_test(1,i)-20], 'YData', [Y_test(2,i)-160 Y_test(2,i)+80]);
end
```



对于 LDA 二维，三维效果如下所示：



对于 PCA 二维，三维效果如下所示：



通过观察结果我们可以看到，LDA 和 PCA 投影的结果似乎都还可以，都将数据正确的分开了，但仔细看，PCA 同类别的数据相比 LDA 要分散一些，这可能与 LDA 的分类目标有关，但实际上，PCA 的分类在二维空间是不太分得开的，这可能与他的维数太低有关，毕竟 PCA 主要是通过特征提取进行类别判断的，因此当在一定范围内，维数越高时，PCA 的效果越好；相比之下，LDA 在低维空间上效果很不错，在维度不大于  $N-1$  时效果最佳，如果超过，可能过拟合数据。因此 PCA 和 LDA 各有优劣，初步判断在 AR\_Gray\_50by40 数据集上将数据降至二维时 LDA 效果较好，三维二者较为接近。

4. PCA 和 LDA 结合的人脸识别方法

在进行前面的实验之后我发现 PCA 和 LDA 方法各自的偏重，LDA 看整体，容易受到噪声影响，于是我们可以先用 PCA 去除噪声，再用 LDA 进行降维。于是我们进行了测试，先将 PCA 下降到 160 维，通过保持 LDA 下降维度于正常 LDA 下降为度一致（与样本和维度前面实验一致），具体效果如下所示：

| dimension      | 1     | 4     | 7     | 10    | 13    | 16    | 19    | 22    | 25    | 28    | 31    | 34    | 37    | 40    | 43    |
|----------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| AR_Gray_50by40 | 0.55  | 0.95  | 1     | 1     | 1     | 1     | 1     | 1     | 1     | 0.95  | 0.95  | 0.95  | 0.95  | 0.925 | 0.95  |
| ORL56_46       | 0.4   | 0.975 | 0.975 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 | 0.925 |
| Yale_face10080 | 0.375 | 0.7   | 0.85  | 0.9   | 0.9   | 0.875 | 0.925 | 0.9   | 0.875 | 0.9   | 0.875 | 0.875 | 0.875 | 0.875 | 0.85  |

通过结果和对比不难发现，结果相比之前两种单独的方法使用时，结果更快地进行收敛，而且在两者表现都比较差的 Yale\_face10080 数据集上，此方法也有相对较好的表现；通过不断的调整合适的下降维度，我相信此算法性能会得到新的提升。

## 四、实验结论或体会

实验结论:

本次实验成功设计了 LDA 算法（包括多种等价模型），并用其和 PCA 在不同数据集上人脸识别的效果进行了对比，还比较了 eigenface 和 fisherface，以及实现两者数据降至二三维度的可视化，取得了较好的结果，同时还设计了一种新的方法来降维数据并取得较好结果，本次实验圆满结束。

实验体会:

通过本实验基本掌握了 LDA 算法，特别是和 PCA 对比起来一起做实验，一方面不仅学会了 LDA 深层的逻辑思想，还对 PCA 有了更深一步的理解，同时还对两者各自的优劣有了更加鲜明的理解。PCA 无监督，假设方差越大，信息量越多，用主成分来表示原始数据可以去除冗余的维度，LDA 有监督，选择的是投影后类内方差小、类间方差大的方向，这样做有利于降维后使得不同类尽可能分开；因此将两者方法结合起来对数据处理可以得到较好的效果；

此外，通过本次实验，对 matlab 编程有了更加深层次的理解，比如在将像素向量映射到 0-1 之间（通过 mat2gray 函数实现）时，发现数据不是 double 型，可明明我读入数据的时候以及转为 double 型，后来通过反复调试才发现，居然还有 complex double 类型，即既有实部还有虚部，因而还需要我们自己将其转化为 double 型才能进行绘图；又如发现了如何在二维空间中显示点对应的图像，虽然过程来的很不易，但还好还是将其掌握了下来；

另外实验过程中也发现自己很多不足的地方，比如数学方面线性代数关于矩阵的知识还得去深造一下，另外对设计新的创新的线性鉴别分析方法或子空间学习方法还没有储备很多的知识，暂时还没有想法涌现，仍需去多读一些论文来包装一下自己；当然算法在一些数据集上的识别率还不是很，还可以继续改进。前路漫漫，还得继续加油！

参考文献:

- [1] [机器学习之基于 LDA 的人脸识别 lda 人脸识别代码讲解-CSDN 博客](#)
- [2] [mat2gray\(\) 函数介绍 mat2gray 函数-CSDN 博客](#)
- [3] [机器学习之 LDA 算法 机器学习 lda-CSDN 博客](#)
- [4] 1-2 PCA-LDA- PCA versus LDA for face recognition
- [5] 1-8 LDA Locality Adaptive Discriminant Analysis

指导教师批阅意见:

成绩评定:

指导教师签字:

年 月 日

备注:

注：1、报告内的项目或内容设置，可根据实际情况加以调整和补充。