

深圳大学实验报告

课程名称 机器学习

项目名称 实验四：SVM 算法

学 院 计算机与软件学院

专 业 软件工程（腾班）

指导教师 赖志辉

报 告 人 洪子敬 学号 2022155033

实验时间 2024 年 4 月 8 日至 2024 年 4 月 21 日

实验报告提交时间 2024 年 4 月 17 日

教务处制

一、实验目的与要求

- 1、分别给出经典的/软间隔/核-SVM 的优化问题并推导其求解优化过程，实现经典的 SVM 算法进行图像识别；在二维平面对二类问题给出 support vector 的一个示例。
- 2、用 PCA、LDA 算法提取前 10,20,30,...,160 维的图像特征，然后再用不同 SVM 进行识别，并比较识别率。
- 3、同时设计一个创新的 SVM 算法，模型与优化内容简要写在本实验报告中，并与经典 SVM 比较性能。

二、实验内容与方法

1. 简要介绍支持向量机原理，包括硬间隔 SVM、软间隔 SVM、核函数 SVM；
2. 用 matlab 实现硬间隔 SVM、软间隔 SVM、以及带有核函数的硬间隔 SVM、软间隔 SVM；
3. 在不同数据集上，用 PCA 和 LDA 算法提取前 10,20,30,...,160 维的图像特征，并加上 SVM 进行人脸识别，计算识别率；同时用 PCA、LDA 与 KNN 相结合进行人脸识别，也计算识别率，比较 SVM 比原本的方法提升了多少识别率。

三、实验步骤与过程

1. 支持向量机 (Support Vector Machines) 原理简介

(1) 基本内容


支持向量机(SVM)是一种二分类模型，它的基本模型是定义在特征空间上的间隔最大的线性分类器，用一个超平面将不同类的样本分开，间隔最大使它有别于感知机；同时 SVM 还包括核技巧，这使得它成为本质上的非线性分类器。SVM 的学习策略是间隔最大化，可形式化为一个求解凸二次规划的问题，也就是最小化正则合页损失函数的问题。

支持向量机可分为硬间隔 SVM、软间隔 SVM、核 SVM（也分软硬间隔）。

(2) 硬间隔 SVM 算法原理

以二分类为例，给定样本数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}, y_i \in \{-1, 1\}$:

SVM 最基本的思想就是在样本空间中找一个划分超平面，将不同类分开，但能将不同类分开的超平面很多，而 SVM 努力寻求一个位于两类训练样本“正中间”的划分超平面，因为此时的划分超平面对训练样本局部扰动的“容忍性”最好，如右所示的例子中，只有中间颜色最深的超平面才对训练集的噪声等因素受得影响最小，即此划分超平面所产生的分类结果是最具鲁棒性的，对未见示例得泛化能力最强。



在样本空间中，我们用如下的线性方程来描述这个超平面

$$w^T x + b = 0$$

其中 $w = (w_1, w_2, \dots, w_m)$ ，是权重项，决定了超平面的方向； b 是位移项，决定了超平面与原点之间的距离，而样本空间中任一点 x 到该超平面的距离可以表示为

$$r = \frac{|w^T x + b|}{\|w\|}$$

假设超平面正确的训练样本分类，对于训练集中每一个点，如果 $y_i = +1$ ，则有 $w^T x_i + b > 0$ ，如果 $y_i = -1$ ，则有 $w^T x_i + b < 0$ ；我们设置以下规则

$$\begin{cases} w^T x_i + b \geq +1, y_i = +1 \\ w^T x_i + b \leq -1, y_i = -1 \end{cases}$$

(右边的 1 表示间距，即是其他常数也可以化成同个样子)

上式可以用下式一个式子表示

$$y_i(w^T x_i + b) \geq 1$$

而距离超平面最近的几个训练样本点使得等式成立，它们被称为“支持向量”，两个异类支持向量到超平面的距离之和为

$$\gamma = \frac{2}{\|w\|} \quad (\text{称为“间隔”})$$

为找到具有“最大间隔”的划分超平面，也找到使得上式最大化的 w 和 b ，即

$$\max_{w,b} \frac{2}{\|w\|} \quad s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m$$

上式可以转化为下式

$$\min_{w,b} \frac{\|w\|^2}{2} \quad s.t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m \quad ①$$

这是 SVM 的硬间隔的基本模型。

而对于硬间隔，我们希望这个超平面可以完全地将不同类的点分开，不允许有任何一个点出错，即超平面应该将两类完全地分开。

①中的式子可以转化为下面的对偶问题：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(w^T x_i + b)) \quad ②$$

其中 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_m)$ ，②式对 w 和 b 求偏导为 0 可得 $w = \sum_{i=1}^m \alpha_i y_i x_i$ ， $\sum_{i=1}^m \alpha_i y_i = 0$ ；

将上面结果代入②中，则可化为

$$\begin{aligned} & \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m y_i w^T x_i - \sum_{i=1}^m \alpha_i y_i b \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m y_i x_i^T w \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i - w^T w \\ &= -\frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

即优化问题可以化为


$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad s.t. \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m$$

解出 α 后，可求出 w 和 b ，即可得到模型

$$f(x) = w^T x + b = \sum_{i=1}^m \alpha_i y_i x_i^T x_i$$

硬间隔求解过程需满足 KKT 条件（凸优化问题求解的重要条件）


$$\begin{cases} \alpha_i \geq 0 \\ y_i f(x_i) \geq 1 \\ \alpha_i (y_i f(x_i) - 1) = 0 \end{cases}$$



最后一个式子表示如果 $\alpha_i = 0$ ，即该样本点在线内部分，对 $f(x)$ 没有影响；如果 $\alpha_i > 0$ ，即该样本点在线上，是支持向量，此时 $y_i f(x_i) = 1$ ；

(3) 软间隔 SVM

对于软间隔 SVM：前面说到我们用一个超平面将不同类的样本数据完全分开的硬间隔，但如果很难将不同类的样本数据线性分开，那么我们只能允许一些出错来达到这样的目的。而这种允许一些错误的方法称为软间隔。此时我们要做的优化就是在前面的基础上使不满足约束的点越少越好，因而优化问题可以变为



$$\min_{w,b} \frac{\|w\|^2}{2} + C \sum_{i=1}^m Z((y_i(w^T x_i + b) - 1))$$

其中 $Z(z)$ 是一个 0/1 函数，具体即点分类正确为 0，分类错误为 1；

我们不难发现这里对每一项位于间隔中的都有相应的惩罚，只是力度不一样，位于中间但分类正确的虽有惩罚但力度小，分类错的力度大。而这里的 C 是个大于 0 的常数，当其无穷大时会迫使所有数满足约束，此时为硬间隔，当 C 取有限值时，允许一些样本不满足约束。但由于 $Z(z)$ 函数非凸非连续，所以一般用其他的凸函数来代替，这里采用 hinge 损失来表示

$$H(z) = \max(0, 1 - z)$$

则上式可以化为

$$\min_{w,b} \frac{\|w\|^2}{2} + C \sum_{i=1}^m H((y_i(w^T x_i + b) - 1))$$

引入松弛变量 $\xi_i \geq 0$ 将上式重写为

$$\min_{w,b,\xi} \frac{\|w\|^2}{2} + C \sum_{i=1}^m \xi_i \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, \dots, m$$

这是软间隔的基本模型

与硬间隔优化类似，这里也是个二次规划问题，于是也有

$$L(w, b, \alpha, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(w^T x_i + b)) - \sum_{i=1}^m \mu_i \xi_i \quad (3)$$

对上式中的 w, b, ξ_i 求偏导并令其为 0 可得

$$w = \sum_{i=1}^m \alpha_i y_i x_i, \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad C = \alpha_i + \mu_i$$

将结果反带入③式中可得其对偶问题为

$$\begin{aligned} & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i \xi_i - \sum_{i=1}^m \alpha_i y_i w^T x_i - \sum_{i=1}^m \alpha_i y_i b - \sum_{i=1}^m \mu_i \xi_i \\ &= \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m (\alpha_i + \mu_i) \xi_i - \sum_{i=1}^m \alpha_i y_i w^T x_i \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i w^T x_i \\ &= \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i - w^T w \\ &= -\frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

因此此题的对偶问题为

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad s.t. \sum_{i=1}^m \alpha_i y_i = 0, 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m$$

解出 α 后，可求出 w 和 b ，即可得到模型也是

$$f(x) = w^T x + b = \sum_{i=1}^m \alpha_i y_i x_i^T x_i$$

软间隔求解过程需满足 KKT 条件（凸优化问题求解的重要条件）

$$\begin{cases} \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, \mu_i \xi_i = 0 \\ y_i f(x_i) \geq 1 - \xi_i \\ \alpha_i (y_i f(x_i) - 1 + \xi_i) = 0 \end{cases}$$

这表示如果 $\alpha_i = 0$ ，即该样本点在间隔外部分，对 $f(x)$ 没有影响；如果 $\alpha_i > 0$ ，说明该样本是支持向量，此时 $y_i f(x_i) = 1 - \xi_i$ ；当 $\alpha_i < C$ ，则 $\mu_i > 0$ ， $\xi_i = 0$ ，此时样本点恰在最大间隔边界上；当 $\alpha_i = C$ ，则由 $\mu_i = 0$ ，此时 $\xi_i \leq 1$ ，样本落在最大间隔的内部。当 $\xi_i > 1$ ，该样本被错误分类。

（4）核函数 SVM

前面的两种情况我们讨论的都是线性可分的情况，但一般在现实任务中并不一定存在一个能够正确划分两类样本的超平面。对于这样的问题，可以采取将样本从原始空间映射到一个高维空间，使得样本再在此空间线性可分。

令 $\varphi(x)$ 表示 x 映射后的特征向量，于是在特征空间中划分超平面的模型可表述为

$$f(x) = w^T \varphi(x) + b$$

对于硬间隔，其优化问题可化为

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad s.t. y_i (w^T \varphi(x_i) + b) \geq 1, i = 1, 2, \dots, m$$

其对偶问题为

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \varphi(x_i)^T \varphi(x_j) \quad s.t. \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m$$

解出 α 后，可求出 w 和 b ，即可得到模型

$$f(x) = w^T \varphi(x) + b = \sum_{i=1}^m \alpha_i y_i \varphi(x_i)^T \varphi(x) + b = \sum_{i=1}^m \alpha_i y_i K(x_i, x) + b$$

这里的 $K(x_i, x)$ 就是核函数，上面的展开称为“支持向量展式”。

同理对于软间隔也有优化问题为

$$\min_{w,b,\xi} \frac{\|w\|^2}{2} + C \sum_{i=1}^m \xi_i \quad s.t. y_i (w^T \varphi(x_i) + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, \dots, m$$

其对偶问题为

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \varphi(x_i)^T \varphi(x_j) \quad s.t. \sum_{i=1}^m \alpha_i y_i = 0, 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m$$

模型的形式与前面一致，只是对应的 α_i

取值范围不同。

而常见核函数如右图所示：


名称	表达式	参数
线性核	$\kappa(x_i, x_j) = x_i^T x_j$	
多项式核	$\kappa(x_i, x_j) = (x_i^T x_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(x_i, x_j) = \exp\left(-\frac{\ x_i - x_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

2. 硬间隔 SVM 的简单编码实现 (matlab)


(1) 实现思想: 在前面我们已经知道了硬间隔 SVM 的待优化问题是一个凸二次规划问题, 这里我们可以采用 matlab 中自带的 quadprog 函数来求解, 该函数返回求解出的 α 。为了方便我采用建立模型的方法, 将支持向量的点以及对应的标签、 α 、超平面的 w 、 b 参数均作为其属性, 以便我们后续的预测以及画图。

(2) 代码实现及测试

下面左图为二分类硬间隔 SVM 的基本代码实现, 这里为测试其实践效果, 我从网上下载了一个简单的线性二分类数据包, 该数据点具体展示如右图所示:



而运行我们的代码并生成对应的线性决策边界具体如下所示:




我们不难发现原数据集中带有噪声项 (左上角), 因而 (左图) 决策边界并不很好, 如果没有噪声 (如右图), 决策边界才变得较为理想。

3. 软间隔 SVM 的简单编码实现 (matlab)


(1) 实现思想: 在前面我们已经知道了软间隔 SVM 的待优化问题也是一个凸二次规划问题, 形式也与硬间隔一致, 唯一不同的是有了一个参数 C 来限制 α 的取值范围。同时我们通过在一定范围内测试, 发现 C 取 0.03 时模型效果最佳, 于是我们设置 $C=0.03$ 。这里我们同样采用 matlab 中自带的 quadprog 函数来求解, 采用建立模型的方法, 将支持向量的点以及对应的标签、 α 、超平面的 w 、 b 参数均作为其属性, 以便我们后续的预测以及画图。

(2) 代码实现及测试

下面左图为软间隔 SVM 的基本实现，这里同样地为了测试其效果，我从网上下载了一个二分类数据集来测试其效果，数据集分布具体如右图所示：



而运行我们的代码并生成对应的线性决策边界具体如下所示：



右图为硬间隔 SVM 画出的决策边界的效果，我们明显可以看到其效果较差；而观察左图软间隔 SVM 画出的效果我们可看到其决策边界化的是比较好的，唯一有些不足的我们可以看出模型在一些边界点的处理还是有些许过拟合，因而下面我们将采取核函数的方法加以改进。


3. 核函数 SVM 的简单编码实现（matlab）

（1）实现思想：在前面我们已经实现了二分类的硬间隔和软间隔 SVM，在先前我们提到加核函数的区别在于 x 的不同，这里我们选取高斯核函数作为 $\varphi(x)$ ，由于 matlab 没有自带函数，所以我自己编写了一个高斯核函数 gaussuanKernel；另外需要做的改变就是将原来代码中计算的 $Q = y_i y_j x_i^T x_j$ 更改为 $Q = y_i y_j \text{gaussuanKernel}(x_i, x_j)$ ，这里我们也将此核函数作为模型的一个属性以便于我们后续替换核函数。

（2）代码实现及测试

同样的针对软间隔给出的数据集，我们实现了软间隔核 SVM 来测试该数据集，具体更改后的代码所测试的模型效果如右图所示：

不难发现此模型没有为了个别点去复杂化决策边界，相反地它画起来更加的平滑，也最大程度的区分开了两类点。



高斯核函数函数代码展示如下：

```
function sim=gaussianKernel(x1, x2, sigma)
% Ensure that x1 and x2 are column vectors
x1 = x1(:); x2 = x2(:);
sim = exp(-(x1-x2)' * (x1-x2)) / (2 * sigma^2);
% sim = exp(-sum((x1-x2).^2)/(2*sigma^2));
end
```

洪子敬 腾班
2022155033

Ps: 硬间隔核 SVM 以及软间隔核 SVM 代码这里不加展示，具体可见提交的压缩包里的代码

4. 多分类 SVM 的简单编码实现 (matlab)

SVM 最初是为了二分类问题所设计的，当初处理多分类时就需要构造合适的多类分类器。目前，构造 SVM 多分类器的方法主要有两种，一是直接法，即直接在目标函数上进行修改，将多个分类面的参数求解合并到一个最优化问题中，这虽然很直接明了但是计算复杂度很高，实现起来比较有困难，只适用于小型问题中；二是间接法，即通过组合多个二分类其来实现多分类的构造，常见的有 one-against-one 和 one-against-all 两种。

- ① 一对多 (one-versus-rest, 简称 OVR SVM)。训练时依次将某个类别的样本归为一类，其余样本归为另一类，对于 k 类样本就构造出了 k 个 SVM 分类器，分类时将样本分类为最大函数分类值的那一类。
- ② 一对一 (one-versus-one, 简称OVO SVM)。在任意两类样本之间设计一个 SVM 分类器，则对于 k 类样本，就构造出了 $k(k-1)/2$ 个 SVM 分类器。当对一个未知样本分类时，得票最多的类别即为该未知样本的类别。

而我们的实现选用第二种 OVO SVM 来实现，因为第一种方法存在缺陷即训练集大小是 $1:M$ ，存在 bias，不是很实用。而此方法的实现思路前面也说过，两两之间建立二分类 SVM 分类器，并通过最终预测来进行投票，票数最高的即为最终分类结果，具体代码如下所示：

```
function prediction=MultiClassSVM(X_train,X_test,Label_train)
% one versus one OVO SVM
% prepare
class_id=unique(Label_train);
cnt=size(class_id,2);
test_num=size(X_test,2);
X_test=X_test';
% train model
models=[];
for i=1:cnt
    for j=i+1:cnt
        class_i_index=find(Label_train==i);
        class_j_index=find(Label_train==j);
        % link by row
        index=[class_i_index class_j_index];
        y=Label_train(index);
        y(y==i)=1;
        y(y==j)=-1;
        model=svmTrain(X_train(:,index)',y',i,j,0.03);
        models=[models model];
    end
end

% predict
prediction=[];
for i=1:test_num
    vote=zeros(cnt,1);
    for j=1:model_num
        model=models(j);
        s=sign(X_test(i,:)*model.w+model.b);
        if(s==1)
            vote(model.C1)=vote(model.C1)+1;
        else
            vote(model.C2)=vote(model.C2)+1;
        end
    end
    [~,index]=sort(vote,'descend');
    prediction=[prediction index(1)];
end
```

洪子敬 腾班
2022155033

5. 不同数据集上的人脸识别对比

这里我们采用了 AR_Gray_50by40、ORL56_46、Yale_face10080 三个人脸数据集来测试不同模型组合之间的效果（识别率衡量），实验采用的模型组合为 PCA+KNN，LDA+KNN，PCA+SVM，LDA+SVM。值得注意的是此处的多分类 SVM 用硬间隔和软间隔区别不大，所以我们统一采用硬间隔进行实验，实验结果展示如下：

PCA+KNN 降到在 10、20、...、160 维上的识别率：

PCA+KNN在不同维度下对人脸数据集上的识别率																HZJ
dimension	10	20	30	40	50	60	70	80	90	100	110	120	130	140	150	160
AR_Gray_50by40	0.6083	0.8000	0.8500	0.8750	0.8833	0.8667	0.8667	0.8667	0.8667	0.8667	0.8667	0.8750	0.8750	0.8750	0.8750	0.8750
ORL56_46	0.8333	0.8917	0.9333	0.9083	0.9167	0.9167	0.9167	0.9167	0.9167	0.9083	0.9083	0.9083	0.9083	0.9000	0.9000	0.9000
Yale_face10080	1.000	1.000	0.9667	0.9333	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667

LDA+KNN 降到在 10、20、...、160 维上的识别率：

LDA+KNN在不同维度下对人脸数据集上的识别率																HZJ
dimension	10	20	30	40	50	60	70	80	90	100	110	120	130	140	150	160
AR_Gray_50by40	0.8833	0.9500	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583
ORL56_46	0.9500	0.9583	0.9333	0.9417	0.9333	0.9250	0.9333	0.9333	0.9417	0.9333	0.9333	0.9250	0.9250	0.9333	0.9250	0.9250
Yale_face10080	1.000	0.967	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000

PCA+SVM 降到在 10、20、...、160 维上的识别率：

PCA+SVM在不同维度下对人脸数据集上的识别率																HZJ
dimension	10	20	30	40	50	60	70	80	90	100	110	120	130	140	150	160
AR_Gray_50by40	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667	0.9667
ORL56_46	0.9167	0.9500	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583	0.9667	0.9667	0.9583	0.9583	0.9583	0.9583	0.9583	0.9583
Yale_face10080	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000

LDA+SVM 降到在 1、5、9、...、41 维上的识别率：

LDA+SVM在不同维度下对人脸数据集上的识别率											HZJ
dimension	1	5	9	13	17	21	25	29	33	37	41
AR_Gray_50by40	0.1083	0.7167	0.8750	0.9250	0.9583	0.9583	0.9583	0.9583	0.9667	0.9667	0.0250
ORL56_46	0.1750	0.8917	0.9500	0.9167	0.9500	0.9500	0.9500	0.9500	0.9417	0.9500	0.0250
Yale_face10080	0.533	0.9667	0.9667	0.100	0.100	0.100	0.100	0.100	0.100	0.233	0.100

值得注意的是对于 AR_Gray_50by40 人脸数据集我们选择 40 类每类 10 张 7 张作为训练集；对于 ORL56_46 人脸数据集我们同样选择 40 类每类 10 张 7 张作为训练集；由于 Yale 人脸数据集类别较少，我们只能选用 10 类每类 10 张 7 张作为训练集. 同时 KNN 分类器 k 取 4。

而由于 SVM 和 KNN 得原理不同，使得 LDA+KNN 不会受到 LDA 下降的维度影响；但 LDA+SVM 在 LDA 下降到的维度大于类别数减一时，会使模型丢掉一些类间差异等关键信息，造成维数灾难，因此 LDA+SVM 我们采用 1 到 41，以 4 为间距进行试验。

通过观察 AR_Gray_50by40 和 ORL56_46 人脸数据集，我们发现将 KNN 换成 SVM 之后模型的识别率都有不同程度得提高，特别是 PCA，提高效果很显著，这应该和 PCA 包括全局的信息有关。在 Yale_face10080 数据集上，我们看到 PCA 在换用 SVM 之后效果显著，不管在那个维度识别率均为 1，由于这个数据集上类别数只有 10，所以 LDA+SVM 只能在 10 以内观察实验结果，我们看到识别率还是不错的，但相比原来还是差点，也间接说明了 LDA+SVM 在处理多类别数据上具有优势，类别数较少时效果较差，这也是 LDA 存在的缺陷。

在总体而言，SVM 分类器的识别效果要更优。

四、实验结论或体会

实验结论：

本次实验成功设计了 SVM 算法,包括硬间隔 SVM、软间隔 SVM、核 SVM、多分类 SVM，同时我们还用多分类 SVM 在 PCA、LDA 降维后进行了人脸识别，并于 PCA+KNN、LDA+KNN 进行了识别率比较，得出了 SVM 分类器的识别效果更优的结论。本次实验圆满结束。

实验体会：

本实验最大的收获就是进一步深刻地认识了 SVM 算法并学会了其硬间隔、软间隔、核函数之间的区别，以及实现上的一些要点，也看到了建立模型的好处所在，同时我也对多分类 SVM 也有了进一步的了解，在用其结合 PCA 和 LDA 降维进行人脸识别进行代码的编写过程中一步步加深了自己的理解。同此我也是第一次通过本次实验见到 LDA 存在缺陷之处（对类别数的要求），之前和 KNN 用的时候并没有发现这个现象，通过本实验不同原理的 SVM 才真正见识到；

此外，本实验采用了 matlab 进行编程，在编写 SVM 算法的过程中我发掘了 matlab 自带的许多功能，比如建立模型、求解二次规划问题等等好处所在，打破了我之前接触 python 之后打压 matlab 的态度，突然发现 matlab 还是很好用的；

另外实验过程中也因为学业繁忙没有时间去思考创新的 SVM 算法，这也算是一个遗憾吧，等之后有时间，一定要静下心来多读些论文，多去思考一些创新性的算法。前路漫漫，还得继续加油！

参考文献：

[1] 9-10 SVM-liblinear SVM

[2] [SVM 多元分类策略 多元 svm-CSDN 博客](#)

[3] [Matlab 笔记 7: 矩阵元素的合并、连接、提取、翻转、排序、平铺复制、提取对角线元素 - 知乎 \(zhihu.com\)](#)

[4] [MATLAB 的 QP 求解器 quadprog 求解线性二次规划 - 知乎 \(zhihu.com\)](#)

指导教师批阅意见：
成绩评定：
指导教师签字： 年 月 日
备注：

注：1、报告内的项目或内容设置，可根据实际情况加以调整和补充。